Projet CRD

Marlon Dujardin Nathan Delattre

2026-02-06

Question 1

Les individus de notre base de données sont les départements, que l'on peut observer à deux périodes différentes : $t_1 = 2013$ et $t_2 = 2023$.
Les variables sont toutes quantitatives et homogènes dans chaque groupe, mais les groupes ne sont pas comparables entre eux car les volumes sont différents entre 2013 et 2023.
Une ACP classique aurait deux problèmes majeurs : les données de 2023 domineraient l'analyse, ce qui ferait que les années ne serait pas du tout comparables.
Pour cela, l'AFM est idéale car elle permet de pondérer chaque groupe de variable afin de permettre une bonne comparaison entre groupes et d'observer les trajectoires des départements entre t_1 et t_2.

Question 2

```r
# Départements en noms de lignes
rownames(data) <- data$Departement
data$Departement <- NULL

# Colonnes par année
cols2013 <- grep("^X2013_", colnames(data), value = TRUE)
cols2023 <- grep("^X2023_", colnames(data), value = TRUE)
```

Afin de comparer les comportements sectoriels indépendamment de la taille des départements, les données ont été transformées en profils (proportions par secteur) avant la mise en œuvre de l'AFM. L'utilisation de profils implique que l'analyse porte sur la structure sectorielle relative des départements et non sur leur niveau total de créations : l'effet taille est ainsi neutralisé.

```r
# Données par année
X2013 <- data[, cols2013]
X2023 <- data[, cols2023]

# Profils (proportions)
prof2013 <- X2013 / rowSums(X2013)
prof2023 <- X2023 / rowSums(X2023)

# Données finales pour l'AFM
data_mfa <- data.frame(prof2013, prof2023)
```

Nous pouvons ainsi procéder à l'AFM :

```r
res.mfa <- MFA(
  data_mfa,
  group = c(length(cols2013), length(cols2023)),
  type = c("s", "s"),
```

```r
  name.group = c("2013", "2023"),
  ncp = 5,
  graph = FALSE
)

res.mfa$eig
```

```
##           eigenvalue percentage of variance cumulative percentage of variance
## comp 1  1.925973e+00           3.092205e+01                          30.92205
## comp 2  9.140755e-01           1.467575e+01                          45.59780
## comp 3  7.077265e-01           1.136276e+01                          56.96056
## comp 4  5.188447e-01           8.330203e+00                          65.29076
## comp 5  3.334586e-01           5.353774e+00                          70.64453
## comp 6  2.462121e-01           3.953007e+00                          74.59754
## comp 7  1.832779e-01           2.942579e+00                          77.54012
## comp 8  1.790216e-01           2.874244e+00                          80.41436
## comp 9  1.638453e-01           2.630585e+00                          83.04495
## comp 10 1.540149e-01           2.472753e+00                          85.51770
## comp 11 1.372061e-01           2.202884e+00                          87.72059
## comp 12 1.178016e-01           1.891338e+00                          89.61193
## comp 13 9.636332e-02           1.547141e+00                          91.15907
## comp 14 7.781810e-02           1.249392e+00                          92.40846
## comp 15 7.408683e-02           1.189486e+00                          93.59794
## comp 16 6.320175e-02           1.014723e+00                          94.61267
## comp 17 4.980124e-02           7.995734e-01                          95.41224
## comp 18 4.925767e-02           7.908463e-01                          96.20309
## comp 19 4.004873e-02           6.429941e-01                          96.84608
## comp 20 3.294234e-02           5.288989e-01                          97.37498
## comp 21 3.006356e-02           4.826792e-01                          97.85766
## comp 22 2.958588e-02           4.750099e-01                          98.33267
## comp 23 2.078643e-02           3.337322e-01                          98.66640
## comp 24 1.933432e-02           3.104182e-01                          98.97682
## comp 25 1.485605e-02           2.385182e-01                          99.21534
## comp 26 1.434908e-02           2.303787e-01                          99.44572
## comp 27 1.297192e-02           2.082680e-01                          99.65398
## comp 28 9.081461e-03           1.458055e-01                          99.79979
## comp 29 7.024987e-03           1.127882e-01                          99.91258
## comp 30 5.445065e-03           8.742211e-02                         100.00000
## comp 31 2.649928e-32           4.254537e-31                         100.00000
## comp 32 1.759171e-32           2.824400e-31                         100.00000
```

```r
fviz_screeplot(res.mfa, addlabels = TRUE)
```

```
## Warning in geom_bar(stat = "identity", fill = barfill, color = barcolor, :
## Ignoring empty aesthetic: `width`.
```

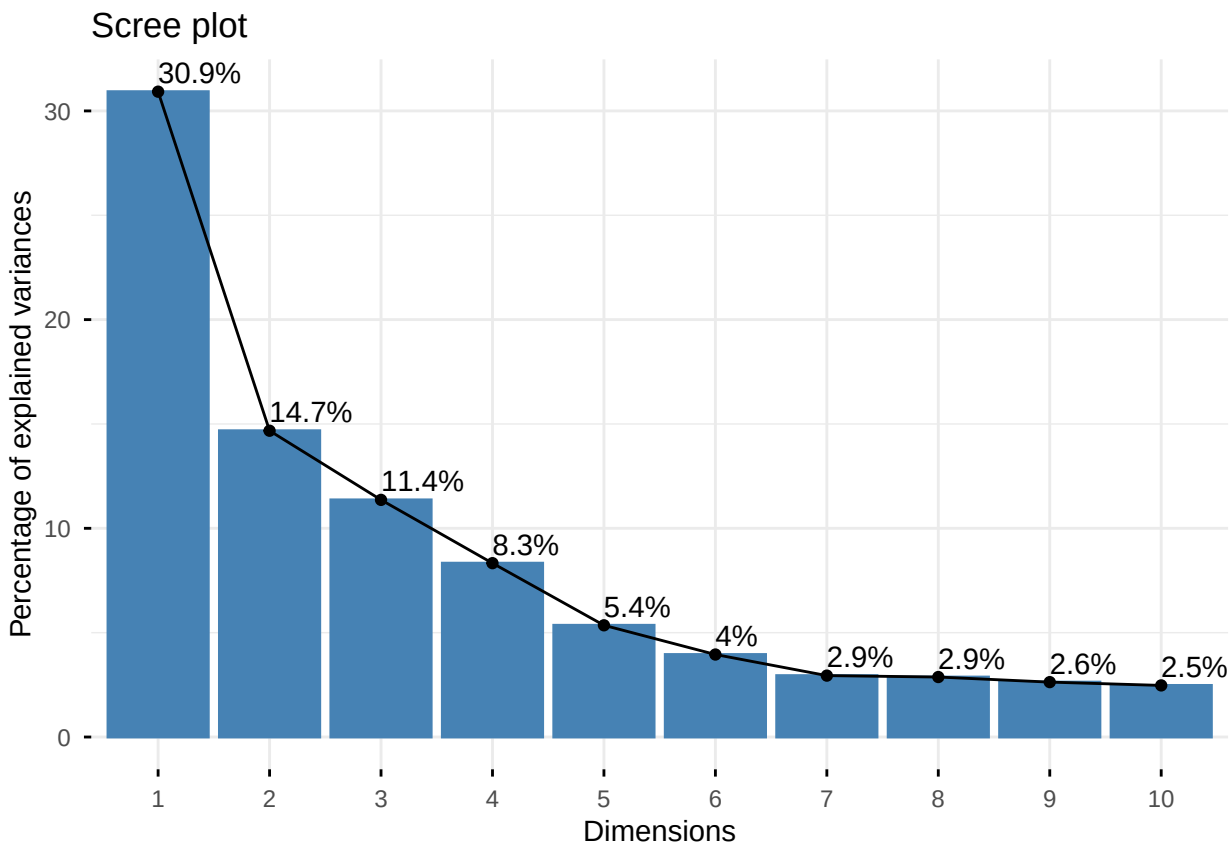

Les deux premières dimensions expliquent 45,6 % de l'inertie totale (30,9 % pour l'axe 1 et 14,7 % pour l'axe 2). La première dimension concentre une part importante de l'information, tandis que les dimensions suivantes présentent des contributions plus faibles.

Le scree plot met en évidence une décroissance progressive des valeurs propres, avec un coude marqué après la première dimension. Le plan factoriel (1,2) apparaît ainsi comme une représentation synthétique pertinente de la structure sectorielle des départements.

```
res.mfa$group$contrib
```

```
##         Dim.1    Dim.2    Dim.3    Dim.4   Dim.5
## 2013 50.03229 57.26586 54.94833 54.39197 65.5006
## 2023 49.96771 42.73414 45.05167 45.60803 34.4994
```

L'axe 1 est construit de manière parfaitement équilibrée par les deux groupes (50 % pour 2013 et 50 % pour 2023). Il traduit donc une structure sectorielle commune aux deux années, révélant une forte stabilité des profils départementaux. L'axe 2 est légèrement plus influencé par 2013 (57 % contre 43 %), ce qui peut suggérer de légères évolutions structurelles, sans rupture majeure.

```
res.mfa$group$RV
```

```
##           2013      2023       MFA
## 2013 1.0000000 0.7887349 0.9507076
## 2023 0.7887349 1.0000000 0.9404782
## MFA  0.9507076 0.9404782 1.0000000
```

Le coefficient RV entre les groupes 2013 et 2023 est égal à 0,79, ce qui indique une forte similarité entre les structures sectorielles des deux années. Les profils départementaux apparaissent donc globalement stables dans le temps. Les évolutions observées relèvent davantage d'ajustements marginaux que de transformations structurelles profondes.

```r
sort(res.mfa$quanti.var$contrib[,1], decreasing = TRUE)[1:5]
```

```
##  X2013_J  X2013_M  X2023_J  X2023_M  X2023_C
## 9.288501 8.619686 8.032237 7.904738 6.665986
```

```r
sort(res.mfa$quanti.var$contrib[,2], decreasing = TRUE)[1:5]
```

```
##   X2013_G   X2013_P   X2023_G   X2013_Q   X2023_R
## 14.429603 10.065851  8.774482  8.564721  7.261169
```

D'après les contributions des variables, l'axe 1 est principalement construit par les secteurs Information-communication (X2013_J : 9,29 ; X2023_J : 8,03) et Activités spécialisées, scientifiques et techniques (X2013_M : 8,62 ; X2023_M : 7,90), ainsi que par l'industrie manufacturière en 2023 (X2023_C : 6,67). Cet axe semble traduire une opposition entre départements davantage orientés vers le tertiaire supérieur (information-communication, activités spécialisées) et ceux dont la structure est relativement plus marquée par d'autres secteurs productifs. Le fait que les mêmes secteurs dominent en 2013 et 2023 va dans le sens d'une stabilité de cette dimension dans le temps.

L'axe 2 est surtout expliqué par le Commerce (X2013_G : 14,43 ; X2023_G : 8,77), l'Enseignement (X2013_P : 10,07), la Santé (X2013_Q : 8,56) et les Arts / activités récréatives (X2023_R : 7,26). Cette dimension correspond ainsi à une opposition liée aux services à la population / économie résidentielle (commerce, enseignement, santé, loisirs) par rapport aux départements où ces secteurs pèsent relativement moins.

```r
fviz_mfa_var(res.mfa, "quanti.var", repel = TRUE)
```

```
## Warning: Using `size` aesthetic for lines was deprecated in ggplot2 3.4.0.
## i Please use `linewidth` instead.
## i The deprecated feature was likely used in the ggpubr package.
##   Please report the issue at <https://github.com/kassambara/ggpubr/issues>.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

```
## Warning: `aes_string()` was deprecated in ggplot2 3.0.0.
## i Please use tidy evaluation idioms with `aes()`.
## i See also `vignette("ggplot2-in-packages")` for more information.
## i The deprecated feature was likely used in the factoextra package.
##   Please report the issue at <https://github.com/kassambara/factoextra/issues>.
## This warning is displayed once every 8 hours.
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

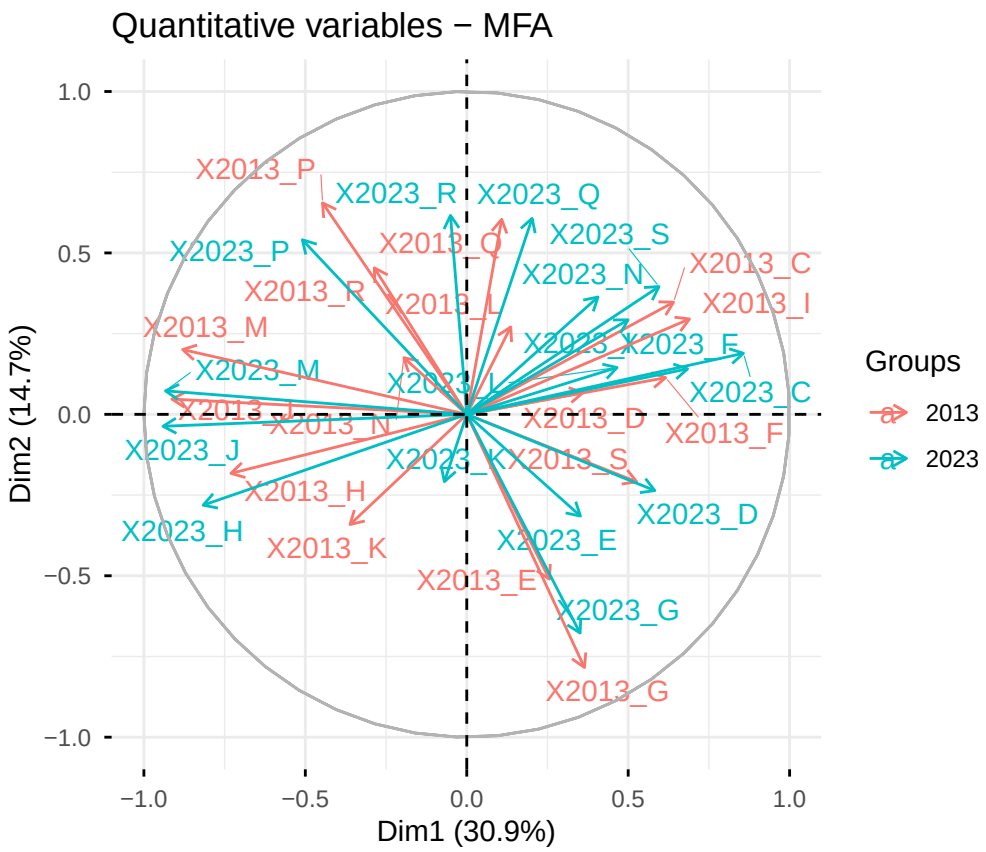

La représentation des variables confirme l'interprétation issue des contributions. L'axe 1 oppose principalement les secteurs liés à l'information-communication et aux activités spécialisées (J, M) aux secteurs plus industriels et productifs (C, F).

L'axe 2 est davantage structuré par les secteurs liés aux services à la population (enseignement, santé, activités récréatives), opposés à d'autres activités comme le commerce ou certains services techniques.

Les flèches correspondant à 2013 et 2023 sont très proches, ce qui confirme la forte similarité des structures sectorielles entre les deux années, en cohérence avec le coefficient RV élevé.

```
fviz_mfa_ind(res.mfa, repel = TRUE)
```

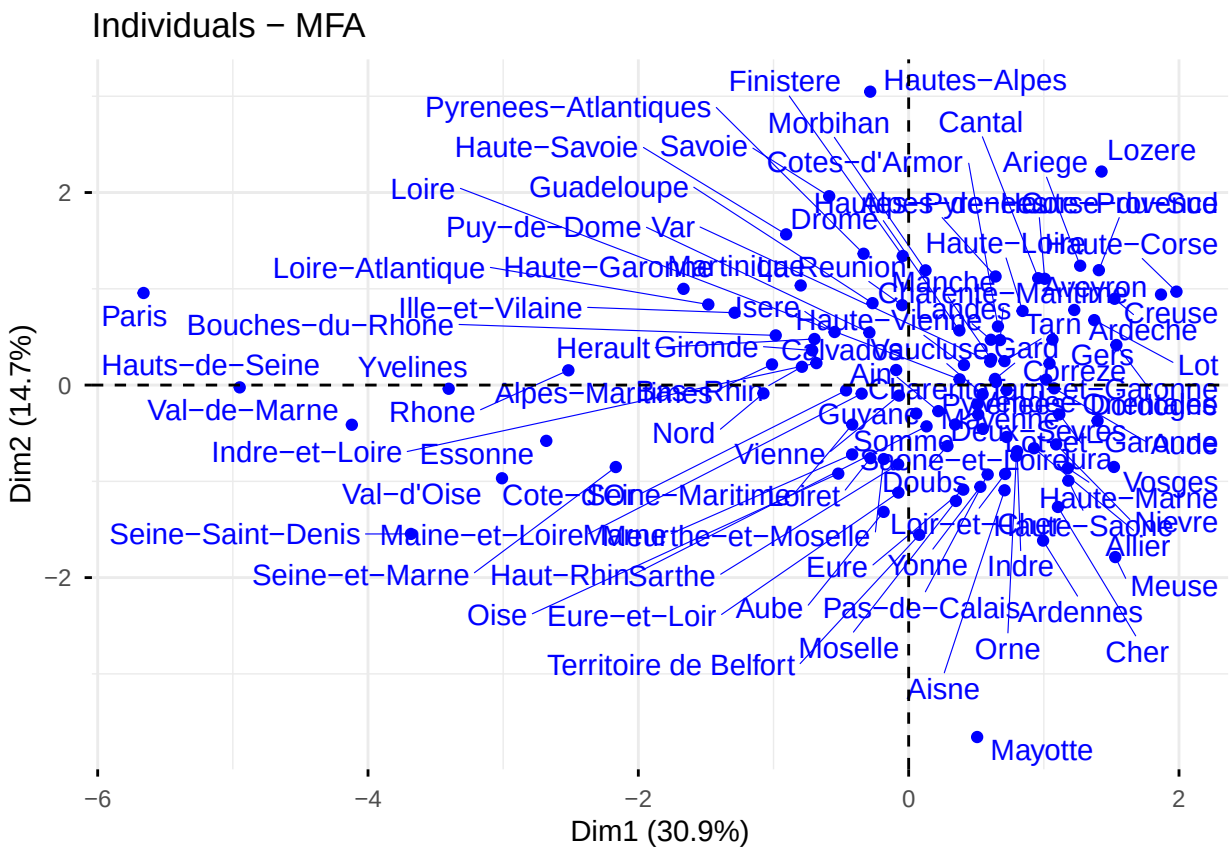

La carte des individus met en évidence une dispersion modérée des départements autour de l'origine, traduisant des différences de structure sectorielle sans opposition extrême. L'axe 1 distingue nettement les départements franciliens (Paris, Hauts-de-Seine, Seine-Saint-Denis, Yvelines, etc.), qui présentent une structure sectorielle spécifique, notamment marquée par le poids des activités de type information-communication et services spécialisés. L'axe 2 oppose certains territoires à profil davantage orienté vers les services à la population ou l'économie résidentielle (commerce, santé, activités récréatives) à d'autres départements au profil différent. Mayotte apparaît comme un territoire atypique sur cette dimension.

Globalement, l'AFM met en évidence une structure sectorielle relativement stable entre 2013 et 2023. Les principales oppositions observées reposent sur le poids relatif du tertiaire supérieur d'une part et des services à la population d'autre part. Les écarts entre départements demeurent modérés, hormis quelques territoires atypiques.

Question 3

```r
coord <- res.mfa$ind$coord

dist_mat <- dist(coord)
cah <- hclust(dist_mat, method = "ward.D2")

fviz_dend(cah, k = 4, rect = TRUE)
```

```
## Warning: The `<scale>` argument of `guides()` cannot be `FALSE`. Use "none" instead as
## of ggplot2 3.3.4.
## i The deprecated feature was likely used in the factoextra package.
##   Please report the issue at <https://github.com/kassambara/factoextra/issues>.
## This warning is displayed once every 8 hours.
```

```
## Call `lifecycle::last_lifecycle_warnings()` to see where this warning was
## generated.
```

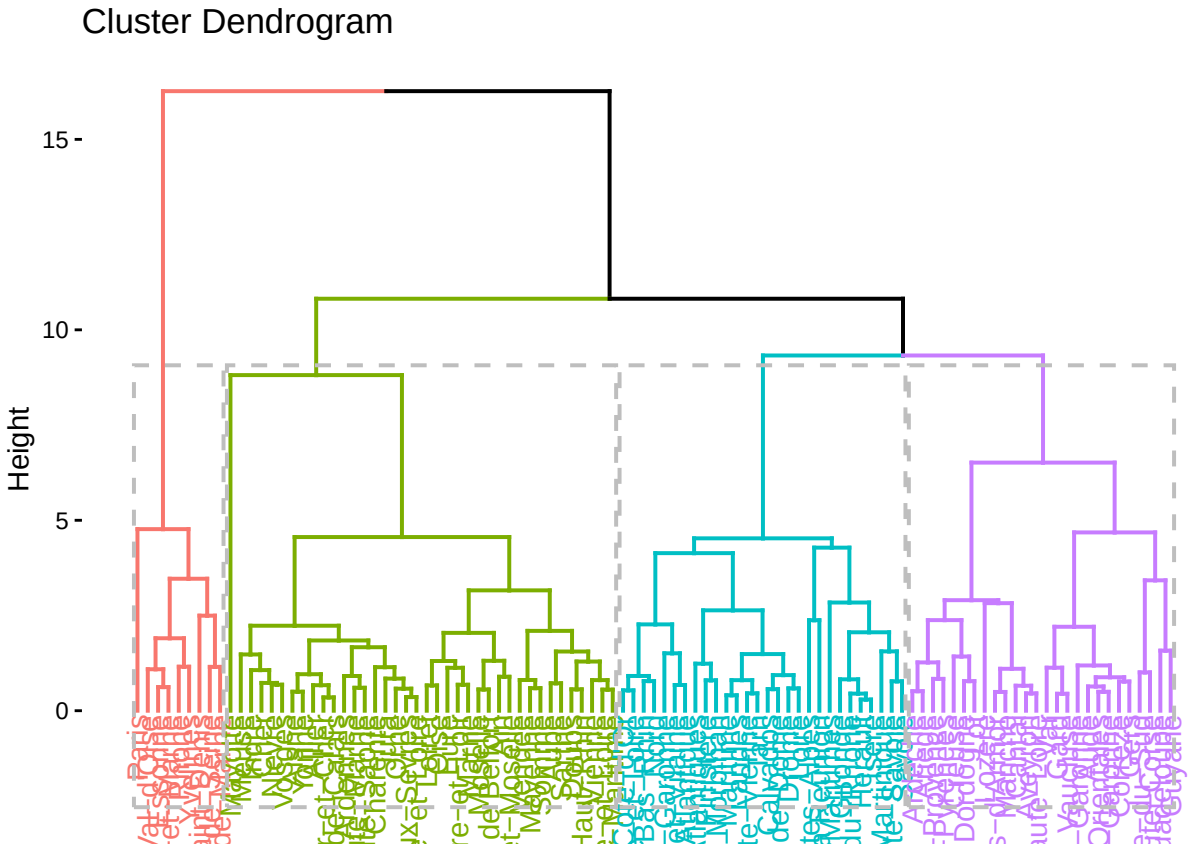


```r
clust <- cutree(cah, k = 4)
table(clust)
```

```
## clust
##  1  2  3  4
## 38 26 28  9
```

```r
split(names(clust), clust)
```

```
## $`1`
##  [1] "Ain"                   "Aisne"                 "Allier"
##  [4] "Ardennes"              "Aube"                  "Charente"
##  [7] "Cher"                  "Deux-Sevres"           "Doubs"
## [10] "Eure"                  "Eure-et-Loir"          "Haut-Rhin"
## [13] "Haute-Marne"           "Haute-Saone"           "Indre"
## [16] "Jura"                  "Loir-et-Cher"          "Loiret"
## [19] "Maine-et-Loire"        "Marne"                 "Mayenne"
## [22] "Mayotte"               "Meurthe-et-Moselle"    "Meuse"
## [25] "Moselle"               "Nievre"                "Oise"
## [28] "Orne"                  "Pas-de-Calais"         "Saone-et-Loire"
## [31] "Sarthe"                "Seine-Maritime"        "Somme"
## [34] "Territoire de Belfort" "Vendee"                "Vienne"
## [37] "Vosges"                "Yonne"
##
## $`2`
```

```
##  [1] "Alpes-de-Haute-Provence" "Ardeche"
##  [3] "Ariege"                  "Aude"
##  [5] "Aveyron"                 "Cantal"
##  [7] "Correze"                 "Corse-du-Sud"
##  [9] "Cotes-d'Armor"           "Creuse"
## [11] "Dordogne"                "Gard"
## [13] "Gers"                    "Guadeloupe"
## [15] "Guyane"                  "Haute-Corse"
## [17] "Haute-Loire"             "Hautes-Pyrenees"
## [19] "Lot"                     "Lot-et-Garonne"
## [21] "Lozere"                  "Manche"
## [23] "Pyrenees-Orientales"     "Tarn-et-Garonne"
## [25] "Var"                     "Vaucluse"
##
## $`3`
##  [1] "Alpes-Maritimes"      "Bas-Rhin"             "Bouches-du-Rhone"
##  [4] "Calvados"             "Charente-Maritime"    "Cote-d'Or"
##  [7] "Drome"                "Finistere"            "Gironde"
## [10] "Haute-Garonne"        "Haute-Savoie"         "Haute-Vienne"
## [13] "Hautes-Alpes"         "Herault"              "Ille-et-Vilaine"
## [16] "Indre-et-Loire"       "Isere"                "La Reunion"
## [19] "Landes"               "Loire"                "Loire-Atlantique"
## [22] "Martinique"           "Morbihan"             "Nord"
## [25] "Puy-de-Dome"          "Pyrenees-Atlantiques" "Savoie"
## [28] "Tarn"
##
## $`4`
## [1] "Essonne"           "Hauts-de-Seine"    "Paris"
## [4] "Rhone"             "Seine-et-Marne"    "Seine-Saint-Denis"
## [7] "Val-d'Oise"        "Val-de-Marne"      "Yvelines"
```

Question 4

Afin d'identifier des regroupements de secteurs présentant des comportements similaires, une classification hiérarchique ascendante (CAH) a été réalisée sur les coordonnées factorielles des variables issues de l'AFM. La méthode de Ward a été retenue, car elle minimise l'inertie intra-classe à chaque étape de fusion.

```r
# Coordonnées des variables sur les axes
coord_var <- res.mfa$quanti.var$coord[, 1:5]

# Distance
dist_var <- dist(coord_var)

# CAH (Ward)
hc_var <- hclust(dist_var, method = "ward.D2")

plot(hc_var)
```

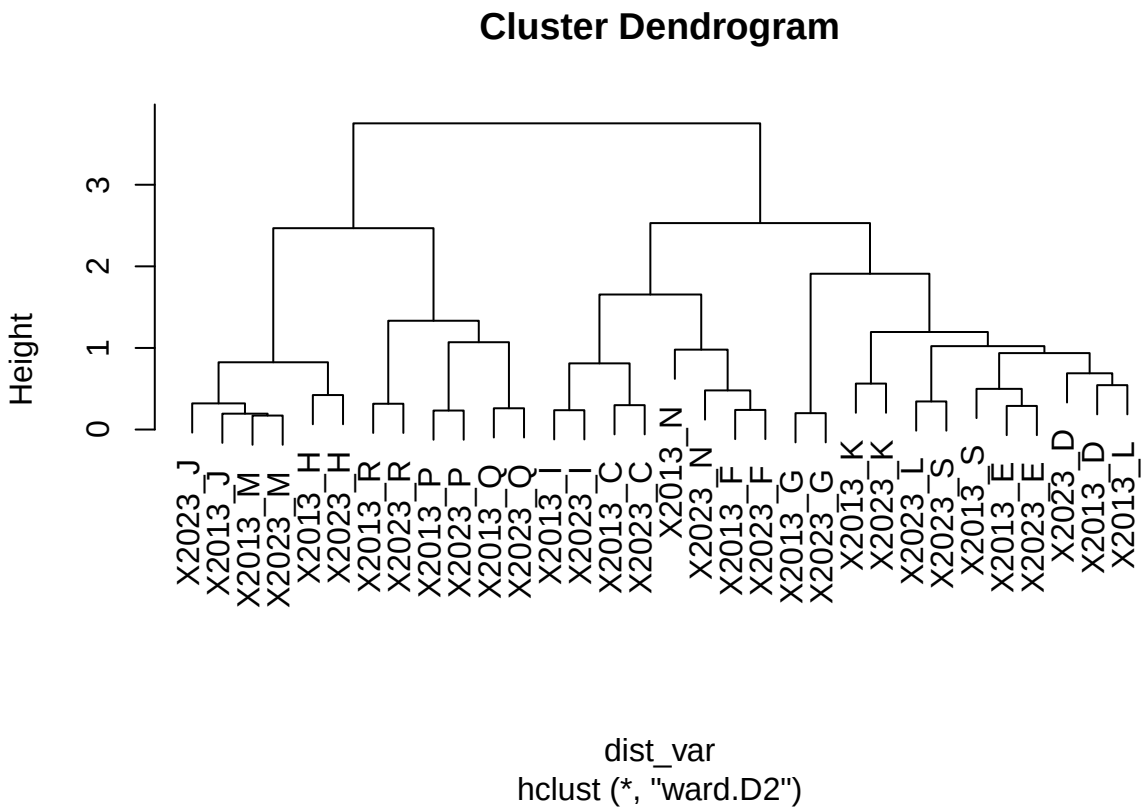

L'examen du dendrogramme met en évidence trois branches principales avant la dernière fusion. On observe un saut marqué de hauteur lors du passage de 3 à 2 classes, traduisant la fusion de groupes relativement hétérogènes. La partition en trois classes apparaît ainsi comme un compromis pertinent entre homogénéité interne et séparation des groupes.

La coupure en trois classes est réalisée comme suit :

```
grp_var <- cutree(hc_var, k = 3)
table(grp_var)
```

```
## grp_var
##  1  2  3
##  8 12 12
```

```
split(names(grp_var), grp_var)
```

```
## $`1`
## [1] "X2013_C" "X2013_F" "X2013_I" "X2013_N" "X2023_C" "X2023_F" "X2023_I"
## [8] "X2023_N"
##
## $`2`
##  [1] "X2013_D" "X2013_E" "X2013_G" "X2013_K" "X2013_L" "X2013_S" "X2023_D"
##  [8] "X2023_E" "X2023_G" "X2023_K" "X2023_L" "X2023_S"
##
## $`3`
##  [1] "X2013_H" "X2013_J" "X2013_M" "X2013_P" "X2013_Q" "X2013_R" "X2023_H"
##  [8] "X2023_J" "X2023_M" "X2023_P" "X2023_Q" "X2023_R"
```

La partition obtenue comporte respectivement 8, 12 et 12 variables, ce qui correspond à trois regroupements sectoriels cohérents (chaque secteur étant représenté deux fois : 2013 et 2023).

La première classe regroupe les secteurs de l'industrie manufacturière (C), de la construction (F), de l'hébergement-restauration (I) ainsi que des services administratifs et de soutien (N). Ces activités relèvent principalement du champ productif et des services directement liés au fonctionnement courant de l'économie. Elles correspondent à des secteurs fortement ancrés dans la production ou dans l'organisation opérationnelle des entreprises.

La deuxième classe rassemble le commerce (G), les activités financières (K), les activités immobilières (L), la production et distribution d'énergie (D), la gestion de l'eau et des déchets (E) ainsi que les autres activités de services (S). Cet ensemble correspond à des services marchands et à des activités de support ou techniques, souvent structurantes pour l'économie locale et indispensables au fonctionnement global des territoires.

La troisième classe regroupe les transports (H), l'information et la communication (J), les activités spécialisées, scientifiques et techniques (M), l'enseignement (P), la santé (Q) ainsi que les arts et activités récréatives (R). Ce groupe correspond au tertiaire supérieur et aux services à la population. Il renvoie à des fonctions plus qualifiées, souvent associées aux dynamiques urbaines et aux fonctions métropolitaines.

On observe par ailleurs que, pour chacun des secteurs, les variables correspondant à 2013 et 2023 appartiennent systématiquement à la même classe. Cette cohérence confirme la stabilité des structures sectorielles entre les deux années, résultat déjà mis en évidence par l'AFM et par le coefficient RV élevé.